

Proyecto 2 — Predicción de Tasa de Divorcios en Guatemala

Bryan Martínez, Adriana Palacios, Brandon Rivera, Javier Benítez, y Pedro Avila

2026-05-10

Variable Respuesta

La variable respuesta es la **tasa de divorcio por cada 100 matrimonios** a nivel departamental y anual, calculada como $(\text{total_divorcios} / \text{total_matrimonios}) \times 100$ para cada par (departamento, año) del período 2009–2022, esta es cuantitativa continua.

La razón principal para tomar esta como la variable a estudiar se debe a los hallazgos que se tuvieron a lo largo del primer proyecto, en donde encontramos que Guatemala acumula más del 38% de los divorcios del país. Pero eso refleja su tamaño poblacional no una mayor propensión al divorcio.

Bajo esta idea en mente, comparar cifras absolutas de divorcio o matrimonio entre departamentos no tiene mucho sentido ya que esto depende o se ve afectado directamente por el tamaño poblacional. Mientras que si comparamos tasas, si logramos tener una medida que permite notar diferencias en cuanto a si en un departamento A ocurren más divorcios que en un departamento B. Al construir una observación por cada par (departamento, año), el modelo puede aprender el patrón histórico de cada departamento y estimar la tasa esperada para combinaciones no vistas durante el entrenamiento, lo que le da utilidad más allá de solo describir el pasado.

Antecedentes

¿Tratas de identificar si un matrimonio va a terminar en divorcio? Esto es algo bastante común. Para tratar de responder a este tipo de incógnitas, recientemente ha surgido el uso de algoritmos de machine learning para tratar de identificar patrones o realizar predicciones. A continuación se van a estar abordando algunos de los casos que fueron estudiados en relación al divorcio.

Predicción de divorcio con Machine Learning

Yöntem et al. (2019) construyeron uno de los conjuntos de datos más utilizados en este campo: entrevistas a parejas divorciadas y casadas, con 54 ítems de la Divorce Predictor Scale derivada de la terapia de Gottman. Con red neuronal y selección de características por correlación alcanzaron una precisión del 98.82 %. El dataset está disponible en UCI Machine Learning Repository y se convirtió en el punto de partida de muchos estudios posteriores, estableciendo que la predicción del divorcio es factible cuando se dispone de variables conductuales bien estructuradas.

Fareed et al. (2022) extendieron ese trabajo combinando máquinas de soporte vectorial (SVM), modelos lineales y redes neuronales bajo un enfoque de ensemble learning. Su hallazgo más importante fue que la selección de variables resulta más determinante que la elección del algoritmo. Dado el problema que se

está estudiando esto es algo que tiene bastante sentido ya que varios factores, como la cantidad de hijos, salarios, nivel educativo, entre otros, pueden impactar directamente en esta ocurrencia. Cabe mencionar que el estudio se puede encontrar en PubMed Central como PMC9293523.

Al-Otaibi et al. (2024), publicado en Scientific Reports, aplicaron ANN, Naïve Bayes y Random Forest sobre datos de Arabia Saudita. Random Forest alcanzó el 91.66 % de precisión tras selección de características, superando a Naïve Bayes cuando las variables estaban correlacionadas. Los autores señalan que la ventaja de Random Forest viene de su capacidad para capturar relaciones no lineales, lo que lo hace especialmente útil con variables categóricas y ordinales como las que se estarán utilizando para este proyecto. Tomando en consideración este factor, uno de los modelos a entrenar va a ser random forest.

Factores económicos y variación regional

Mbaye et al. (2020) estudiaron la distribución geográfica del divorcio en Omán usando modelos de regresión espacial. Sus resultados muestran que el empleo femenino, el nivel educativo y la proporción de residencia urbana explican una parte importante de la varianza en las tasas locales. Además, encontraron autocorrelación espacial positiva: las wilayas con tasas altas tienden a ser vecinas de otras con tasas igualmente altas. Ese mismo patrón apareció en el análisis de clustering del Proyecto 1, donde los departamentos del altiplano occidental de Guatemala (Totonicapán, Sololá, Quiché) forman un bloque con proporciones bajas de divorcio respecto al matrimonio.

Papageorgiou y Velásquez (2025) analizaron 83 países entre 1990 y 2019 y encontraron que las crisis bancarias y cambiarias se asocian con aumentos en las tasas de divorcio, con rezagos de uno a tres años. Esto ayuda a entender los picos observados en Guatemala después de 2019 y abre la posibilidad de incorporar variables económicas en versiones futuras del modelo, si es que se lograra encontrar un dataset que proporcione estos datos de forma accesible.

Esteve et al. (2023) documentaron los cambios en el patrón del matrimonio en siete países de América Latina, concluyendo que la expansión educativa y la urbanización son los principales factores detrás del retraso en la edad al matrimonio en la región. Interesantemente, ese retraso no fue confirmado para Guatemala en el período 2009–2022 durante el análisis exploratorio, lo que ya es un resultado relevante en sí mismo para el contexto regional.

Tomando todo esto en consideración y dada la limitación del dataset con el que se estuvo trabajando del INE en el último proyecto, se decidió expandir la búsqueda. Se encontró que el GDL comparte datos de forma anual que permiten tener algunos índices de desarrollo económicos. Esto permite expandir la perspectiva o la posibilidad del modelo de identificar si ciertos factores económicos tienen un impacto sobre la tasa de divorcios. El cual será el enfoque de estudio a lo largo de este proyecto.

Referencias

- Al-Otaibi, A., Alotaibi, B., & Alzahrani, I. (2024). Divorce prediction using machine learning algorithms in Ha'il region, KSA. *Scientific Reports*, 14, 481. <https://www.nature.com/articles/s41598-023-50839-1>
- Fareed, S., Ghani, U., Ali, S., & Hussain, W. (2022). Predicting divorce prospect using ensemble learning: Support vector machine, linear model, and neural network. *Computational Intelligence and Neuroscience*, 2022, 3687598. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9293523/>
- Mbaye, E. H., Al-Kindi, M., & Al-Alawi, A. (2020). The effects of sociodemographic characteristics on divorce rates in Oman: Spatial modeling of marital separations. *Journal of Population Research*, 37(3), 225–247. <https://www.researchgate.net/publication/340111582>
- Papageorgiou, I., & Velásquez, R. (2025). When the economy breaks down, do marriages follow? Crisis type and family dissolution across 83 countries (1990–2019). *Applied Research in Quality of Life*. <https://link.springer.com/article/10.1007/s11482-025-10540-z>

Yöntem, M. K., Adem, K., İlhan, T., & Kılıçarslan, S. (2019). Divorce prediction using correlation based feature selection and artificial neural networks. *Neuşehir Hacı Bektaş Veli University Journal of ISS*, 9(1), 259–273. https://www.researchgate.net/publication/373398266_Divorce_Prediction_Using_Machine_Learning_Methodology

Algoritmos a Utilizar

Dado el perfil del dataset —308 observaciones a nivel departamento-año, variable respuesta continua, mezcla de predictores numéricos y una variable categórica— se seleccionaron tres algoritmos para comparar:

Regresión Lineal Múltiple

El modelo más simple de los tres y el que sirve como línea base. Permite cuantificar directamente el peso de cada predictor sobre la tasa de divorcio y es fácil de interpretar. Su limitación real es el supuesto de linealidad: los datos del INE ya mostraron asimetría positiva en la distribución de valores, lo que sugiere que las relaciones probablemente no son lineales. Aun así, sirve como referencia honesta para evaluar si los modelos más complejos realmente aportan algo.

Árbol de Decisión (Regression Tree)

Captura relaciones no lineales y umbrales naturales sin necesidad de especificarlos de antemano. Por ejemplo, puede detectar por sí solo que los departamentos por debajo de cierto volumen de matrimonios se comportan de manera distinta. No requiere normalización de variables y su estructura de reglas es directamente interpretable. El riesgo es el sobreajuste cuando la profundidad no se controla, por lo que se aplicará poda mediante validación cruzada.

Random Forest (Regresión)

De los tres, es el que tiene mayores expectativas de desempeño para este problema. Maneja bien la combinación de variables numéricas y categóricas, no asume ninguna forma funcional, y es robusto frente a valores atípicos. Al-Otaibi et al. (2024) y Dogan y Kılınç (2025) reportan consistentemente que Random Forest supera a modelos individuales en problemas demográficos con perfiles similares al nuestro. Adicionalmente, el índice de importancia de variables (Gini importance) permitirá identificar qué predictores —departamento, tendencia temporal o indicadores de desarrollo humano— pesan más en la predicción, lo cual es una conclusión sustantiva sobre Guatemala más allá de la métrica de error.

Construcción del Dataset

El dataset final se construye combinando tres fuentes: los registros de matrimonios y divorcios por departamento del INE (2009–2022), y los índices de desarrollo humano subnacionales del Global Data Lab (GDL) para el mismo período.

Fuentes de datos

- **INE Guatemala** — `matrimonios_depto_mes.csv` y `divorcios_depto_mes.csv`: contienen el total de matrimonios y divorcios registrados por departamento y mes. Se utilizan únicamente las filas con `mes` vacío y `nivel_geo == "departamento"`, que corresponden a los totales anuales por departamento.
- **Global Data Lab (GDL)** — 14 archivos CSV, uno por año (2009–2022): contienen los índices de desarrollo humano (HDI compuesto, salud, educación e ingreso) para las 8 regiones administrativas de Guatemala. Dado que el GDL opera a nivel regional y no departamental, se construye un mapa explícito que asigna cada uno de los 22 departamentos a su región correspondiente.

Normalización de nombres de departamentos

```
norm_depto <- function(x) {  
  x %>%  
    str_trim() %>%  
    str_squish() %>%  
    stri_trans_general("Latin-ASCII") %>%  
    str_to_lower()  
}
```

Carga y limpieza de datos del INE

```
matrimonios_anual <- read_csv("../matrimonios_depto_mes.csv", show_col_types = FALSE) %>%  
  filter(nivel_geo == "departamento", is.na(mes)) %>%  
  mutate(departamento = norm_depto(departamento)) %>%  
  group_by(anio, departamento) %>%  
  summarise(total_matrimonios = sum(valor, na.rm = TRUE), .groups = "drop")  
  
divorcios_anual <- read_csv("../divorcios_depto_mes.csv", show_col_types = FALSE) %>%  
  filter(nivel_geo == "departamento", is.na(mes)) %>%  
  mutate(departamento = norm_depto(departamento)) %>%  
  group_by(anio, departamento) %>%  
  summarise(total_divorcios = sum(valor, na.rm = TRUE), .groups = "drop")  
  
dataset_ine <- matrimonios_anual %>%  
  inner_join(divorcios_anual, by = c("anio", "departamento")) %>%  
  mutate(tasa_divorcio_por_100 = (total_divorcios / total_matrimonios) * 100)
```

Carga y consolidación de datos del GDL

```
archivos_gdl <- list.files(pattern = "GDL-Human-Development.*\\.csv$")  
  
gdl_consolidado <- map_dfr(archivos_gdl, read_csv, show_col_types = FALSE) %>%  
  filter(Level == "Subnat") %>%  
  select(region_gdl = Region, anio = Year, shdi, healthindex, edindex, incindex)
```

Mapecto de departamentos a regiones GDL

```
region_map <- tibble(  
  departamento = c(  
    "guatemala",  
    "alta verapaz", "baja verapaz",  
    "el progreso", "izabal", "zacapa", "chiquimula",  
    "santa rosa", "jalapa", "jutiapa",  
    "chimaltenango", "sacatepequez", "escuintla",  
    "san marcos", "quetzaltenango", "retalhuleu",  
    "suchitepequez", "solola", "totonicapan",  
    "huehuetenango", "quiche",  
    "peten"  
  ),  
  region_gdl = c(  
    "Metropolitan",  
    "North", "North",  
    "North-Oriental", "North-Oriental", "North-Oriental", "North-Oriental",  
    "South-Oriental", "South-Oriental", "South-Oriental",  
    "Central", "Central", "Central",  
    "South-Occidental", "South-Occidental", "South-Occidental",  
    "South-Occidental", "South-Occidental", "South-Occidental",  
    "North-Occidental", "North-Occidental",  
    "Peten"  
  )  
)
```

Join final y dataset completo

```
dataset_final <- dataset_ine %>%  
  left_join(region_map, by = "departamento") %>%  
  left_join(gdl_consolidado, by = c("region_gdl", "anio")) %>%  
  select(departamento, anio, total_matrimonios, total_divorcios,  
         shdi, healthindex, edindex, incindex,  
         tasa_divorcio_por_100)  
  
glimpse(dataset_final)
```

```
## Rows: 308  
## Columns: 9  
## $ departamento      <chr> "alta verapaz", "baja verapaz", "chimaltenango", ~  
## $ anio               <dbl> 2009, 2009, 2009, 2009, 2009, 2009, 2009, 2009, ~  
## $ total_matrimonios  <dbl> 4300, 1334, 3099, 1766, 786, 2859, 11824, 5276, ~  
## $ total_divorcios    <dbl> 129, 66, 56, 91, 47, 160, 1024, 84, 86, 79, 140, ~  
## $ shdi               <dbl> 0.614, 0.614, 0.674, 0.657, 0.657, 0.674, 0.789, ~  
## $ healthindex        <dbl> 0.768, 0.768, 0.758, 0.753, 0.753, 0.758, 0.790, ~  
## $ edindex            <dbl> 0.517, 0.517, 0.591, 0.562, 0.562, 0.591, 0.783, ~  
## $ incindex           <dbl> 0.584, 0.584, 0.683, 0.669, 0.669, 0.683, 0.794, ~  
## $ tasa_divorcio_por_100 <dbl> 3.000000, 4.947526, 1.807035, 5.152888, 5.979644~
```

```
cat("Observaciones totales:", nrow(dataset_final), "\n")
```

```
## Observaciones totales: 308
```

```
cat("Departamentos únicos:", n_distinct(dataset_final$departamento), "\n")
```

```
## Departamentos únicos: 22
```

```
cat("Años cubiertos:", min(dataset_final$anio), "-", max(dataset_final$anio), "\n")
```

```
## Años cubiertos: 2009 - 2022
```

```
cat("Valores faltantes:\n")
```

```
## Valores faltantes:
```

```
colSums(is.na(dataset_final))
```

```
##      departamento      anio      total_matrimonios
##      0              0              0
##      total_divorcios      shdi      healthindex
##      0              0              0
##      edindex      incindex tasa_divorcio_por_100
##      0              0              0
```

Conjuntos de Entrenamiento y Prueba

Método de partición

Dado que el dataset tiene una dimensión temporal explícita —cada observación corresponde a un departamento en un año específico— se utilizó una **partición temporal** en lugar de una partición aleatoria. Dividir aleatoriamente introduciría fuga de datos: el modelo podría entrenarse con información de 2021 y luego evaluarse en 2020, lo que no refleja ningún escenario de uso real.

La partición se define así:

- **Entrenamiento:** años 2009 a 2020 — el modelo aprende los patrones históricos.
- **Prueba:** años 2021 y 2022 — se evalúa qué tan bien generaliza a años que no vio.

```
train_set <- dataset_final %>% filter(anio <= 2020)
test_set  <- dataset_final %>% filter(anio > 2020)
```

```
cat("Entrenamiento:", nrow(train_set), "observaciones",
    sprintf("(%.1f%%)\n", 100 * nrow(train_set) / nrow(dataset_final)))
```

```
## Entrenamiento: 264 observaciones (85.7%)
```

```
cat("Prueba:      ", nrow(test_set), "observaciones",
    sprintf("(%.1f%%)\n", 100 * nrow(test_set) / nrow(dataset_final)))
```

```
## Prueba:      44 observaciones (14.3%)
```

El conjunto de entrenamiento cubre 12 años $\times$ 22 departamentos = **264 observaciones (85.7 %)** y el de prueba cubre 2 años $\times$ 22 departamentos = **44 observaciones (14.3 %)**. La proporción no es la clásica 80/20 exacta, pero es la partición más honesta para datos con estructura de panel temporal.

Análisis de valores atípicos en la variable respuesta

Como la variable respuesta es cuantitativa continua, no aplica un análisis de balance. En su lugar se analizan los valores atípicos usando el criterio del rango intercuartílico (IQR): se considera atípico cualquier valor por debajo de $Q1 - 1.5 \times IQR$ o por encima de $Q3 + 1.5 \times IQR$.

```
Q1 <- quantile(dataset_final$tasa_divorcio_por_100, 0.25, na.rm = TRUE)
Q3 <- quantile(dataset_final$tasa_divorcio_por_100, 0.75, na.rm = TRUE)
IQR_val <- IQR(dataset_final$tasa_divorcio_por_100, na.rm = TRUE)

lim_inf <- Q1 - 1.5 * IQR_val
lim_sup <- Q3 + 1.5 * IQR_val

cat(sprintf("Q1: %.3f | Q3: %.3f | IQR: %.3f\n", Q1, Q3, IQR_val))
```


```
## Q1: 3.975 | Q3: 9.658 | IQR: 5.683
```

```
cat(sprintf("Límite inferior: %.3f | Límite superior: %.3f\n", lim_inf, lim_sup))
```

```
## Límite inferior: -4.549 | Límite superior: 18.182
```

```
ggplot(dataset_final, aes(y = tasa_divorcio_por_100)) +
  geom_boxplot(outlier.colour = "red", outlier.size = 2) +
  labs(
    title = "Distribución de la tasa de divorcio por cada 100 matrimonios",
    y      = "Divorcios por cada 100 matrimonios"
  ) +
  theme_minimal()
```

Distribución de la tasa de divorcio por cada 100 matrimonios



```
atipicos <- dataset_final %>%
  filter(tasa_divorcio_por_100 > lim_sup | tasa_divorcio_por_100 < lim_inf) %>%
  arrange(desc(tasa_divorcio_por_100))

cat("Total de observaciones atípicas:", nrow(atipicos), "\n\n")
```

```
## Total de observaciones atípicas: 8
```

```
atipicos %>% select(departamento, anio, tasa_divorcio_por_100, total_matrimonios, total_divorcios)
```

```
## # A tibble: 8 x 5
##   departamento    anio tasa_divorcio_por_100 total_matrimonios total_divorcios
##   <chr>          <dbl>         <dbl>          <dbl>          <dbl>
## 1 guatemala      2019         25.5          14477           3687
## 2 guatemala      2021         22.6          15382           3481
## 3 el progreso    2021         22.6           1027            232
## 4 guatemala      2022         22.4          15623           3494
## 5 el progreso    2022         18.7           979             183
## 6 quetzaltenango 2022         18.7           5131            957
## 7 jalapa         2022         18.6           1444             268
## 8 retalhuleu     2022         18.2           1927             351
```

Los atípicos detectados son observaciones reales del dataset, no errores de captura. El departamento de Guatemala concentra sistemáticamente las tasas más altas, lo que es consistente con los resultados del

Proyecto 1: ya en el clustering aparecía como un caso separado del resto del país. Esta diferencia responde a factores estructurales —mayor acceso a servicios legales, urbanización, densidad poblacional— y no a ruido en los datos.

Por eso **no se eliminan**. Los tres modelos los recibirán tal como están durante el entrenamiento. Si un modelo logra aprender que Guatemala se comporta distinto al resto, eso es precisamente lo que queremos que capture.