

Proyecto 2 — Predicción de Tasa de Divorcios en Guatemala

Bryan Martínez, Adriana Palacios, Brandon Rivera, Javier Benítez, y Pedro Avila

2026-05-14

Variable Respuesta

La variable respuesta es la **tasa de divorcio por cada 100 matrimonios** a nivel departamental y anual, calculada como $(\text{total_divorcios} / \text{total_matrimonios}) * 100$ para cada par (departamento, año) del período 2009–2022. Es una variable cuantitativa continua.

La razón principal para tomarla como variable a estudiar se debe a los hallazgos del primer proyecto, en donde encontramos que Guatemala acumula más del 38% de los divorcios del país. Pero eso refleja su tamaño poblacional, no una mayor propensión al divorcio.

Con esto en mente, comparar cifras absolutas de divorcio o matrimonio entre departamentos no tiene mucho sentido, ya que se ve afectado directamente por el tamaño poblacional. Comparar tasas sí permite notar diferencias reales entre departamentos: si en el departamento A ocurren más divorcios por cada 100 matrimonios que en el B, eso ya nos dice algo independientemente del tamaño de cada uno. Al construir una observación por cada par (departamento, año), el modelo puede aprender el patrón histórico de cada departamento y estimar la tasa esperada para combinaciones no vistas durante el entrenamiento, lo que le da utilidad más allá de solo describir el pasado.

Antecedentes

¿Qué hace que un matrimonio termine en divorcio? Para tratar de responder a este tipo de preguntas, recientemente ha surgido el uso de algoritmos de machine learning que permiten identificar patrones y realizar predicciones. Como equipo, consideramos que este es uno de los fenómenos más relevantes a estudiar actualmente, en donde vemos cómo los matrimonios son más propensos a terminar en divorcio. A continuación se presentan algunos de los estudios más relevantes encontrados en relación al tema.

Predicción de divorcio con Machine Learning

Yöntem et al. (2019) construyeron uno de los conjuntos de datos más utilizados en este campo: entrevistas a parejas divorciadas y casadas, con 54 ítems de la Divorce Predictor Scale derivada de la terapia de Gottman. Con red neuronal y selección de características por correlación alcanzaron una precisión del 98.82 %. El dataset está disponible en UCI Machine Learning Repository y se convirtió en el punto de partida de muchos estudios posteriores, estableciendo que la predicción del divorcio es factible cuando se dispone de variables conductuales bien estructuradas.

Fareed et al. (2022) extendieron ese trabajo combinando máquinas de soporte vectorial (SVM), modelos lineales y redes neuronales bajo un enfoque de ensemble learning. Su hallazgo más importante fue que la

selección de variables resulta más determinante que la elección del algoritmo. Dado el problema que se está estudiando, esto tiene bastante sentido ya que varios factores, como la cantidad de hijos, salarios y nivel educativo, pueden impactar directamente en el divorcio. Cabe mencionar que el estudio se puede encontrar en PubMed Central como PMC9293523.

Al-Otaibi et al. (2024), publicado en Scientific Reports, aplicaron ANN, Naïve Bayes y Random Forest sobre datos de Arabia Saudita. Random Forest alcanzó el 91.66 % de precisión tras selección de características, superando a Naïve Bayes cuando las variables estaban correlacionadas. Los autores señalan que la ventaja de Random Forest viene de su capacidad para capturar relaciones no lineales, lo que lo hace especialmente útil con variables categóricas y ordinales como las que se estarán utilizando para este proyecto. Tomando en consideración este factor, uno de los modelos a entrenar va a ser random forest. Asimismo, lo encontrado en este artículo es bastante llamativo porque nos damos cuenta de que el divorcio probablemente no se puede explicar a través de una relación lineal en su totalidad. Algo que cobra sentido si se consideran los factores emocionales, que difícilmente siguen un patrón lineal.

Dogan y Kılınç (2025), en Social Science Computer Review, analizaron la Encuesta de Estructura Familiar de Turquía usando Random Forest y regresión logística. Los predictores más robustos que encontraron fueron la edad al contraer matrimonio, los años de convivencia y el nivel educativo. Aunque nuestro dataset no cuenta con variables individuales de ese tipo, el análisis exploratorio del Proyecto 1 ya mostró que los matrimonios se concentran en el rango 20–24 años y los divorcios en el de 30–34 años, lo que sugiere que la distribución etaria agregada puede capturar parte de ese comportamiento a nivel departamental.

Factores económicos y variación regional

Mbaye et al. (2020) estudiaron la distribución geográfica del divorcio en Omán usando modelos de regresión espacial. Sus resultados muestran que el empleo femenino, el nivel educativo y la proporción de residencia urbana explican una parte importante de la varianza en las tasas locales. Además, encontraron autocorrelación espacial positiva: las wilayas con tasas altas tienden a ser vecinas de otras con tasas igualmente altas. Ese mismo patrón apareció en el análisis de clustering del Proyecto 1, donde los departamentos del altiplano occidental de Guatemala (Totonicapán, Sololá, Quiché) forman un bloque con proporciones bajas de divorcio respecto al matrimonio.

Papageorgiou y Velásquez (2025) analizaron 83 países entre 1990 y 2019 y encontraron que las crisis bancarias y cambiarias se asocian con aumentos en las tasas de divorcio, con rezagos de uno a tres años. Esto ayuda a entender los picos observados en Guatemala después de 2019 y abre la posibilidad de incorporar variables económicas en versiones futuras del modelo, si es que se lograra encontrar un dataset que proporcione estos datos de forma accesible.

Esteve et al. (2023) documentaron los cambios en el patrón del matrimonio en siete países de América Latina, concluyendo que la expansión educativa y la urbanización son los principales factores detrás del retraso en la edad al matrimonio en la región. Interesantemente, ese retraso no fue confirmado para Guatemala en el período 2009–2022 durante el análisis exploratorio, lo que ya es un resultado relevante en sí mismo para el contexto regional.

Tomando todo esto en consideración y dada la limitación del dataset del INE trabajado en el proyecto anterior, se decidió expandir la búsqueda. Se encontró que el GDL publica datos anuales con índices de desarrollo humano a nivel subnacional. Esto le da al modelo la posibilidad de identificar si ciertos factores como el nivel educativo, de salud o de ingreso tienen un impacto sobre la tasa de divorcios, que es precisamente el enfoque de estudio de este proyecto.

Algoritmos a Utilizar

Dado el perfil del dataset 308 observaciones a nivel departamento-año, variable respuesta continua, mezcla de predictores numéricos y una variable categórica— se seleccionaron tres algoritmos para comparar:

Regresión Lineal Múltiple

El modelo más simple de los tres y el que sirve como línea base. Permite cuantificar directamente el peso de cada predictor sobre la tasa de divorcio y es fácil de interpretar. Su limitación real es el supuesto de linealidad: los datos del INE ya mostraron asimetría positiva en la distribución de valores, lo que sugiere que las relaciones probablemente no son lineales. Aun así, sirve como referencia para evaluar si los modelos más complejos realmente aportan algo, y de si realmente existe una relación lineal entre las variables predictoras.

Árbol de Decisión

Captura relaciones no lineales y umbrales naturales sin necesidad de especificarlos de antemano. Por ejemplo, puede detectar por sí solo que los departamentos por debajo de cierto volumen de matrimonios se comportan de manera distinta. No requiere normalización de variables y su estructura de reglas es directamente interpretable. El riesgo es el sobreajuste cuando la profundidad no se controla, por lo que se aplicará poda mediante validación cruzada. Así mismo estaremos comparando los resultados entre el dataset de entrenamiento y el de prueba para poder validar si hay un declive considerable en las métricas cuando pasamos al dataset de prueba.

Random Forest

De los tres, es el que tiene mayores expectativas de desempeño para este problema. Maneja bien la combinación de variables numéricas y categóricas, no asume ninguna forma funcional, y es robusto frente a valores atípicos. Al-Otaibi et al. (2024) y Dogan y Kılınç (2025) reportan consistentemente que Random Forest supera a modelos individuales en problemas demográficos con perfiles similares al nuestro. Adicionalmente, el índice de importancia de variables (Gini importance) permitirá identificar qué predictores, departamento, tendencia temporal o indicadores de desarrollo humano, pesan más en la predicción, lo cual es una conclusión sustantiva sobre Guatemala más allá de la métrica de error.

Construcción del Dataset

El dataset final se construye combinando tres fuentes: los registros de matrimonios y divorcios por departamento del INE (2009–2022), y los índices de desarrollo humano subnacionales del Global Data Lab (GDL) para el mismo período.

Fuentes de datos

- **INE Guatemala** `matrimonios_depto_mes.csv` y `divorcios_depto_mes.csv`: contienen el total de matrimonios y divorcios registrados por departamento y mes. Se utilizan únicamente las filas con `mes` vacío y `nivel_geo == "departamento"`, que corresponden a los totales anuales por departamento.
- **Global Data Lab (GDL)** 14 archivos CSV, uno por año (2009–2022): contienen los índices de desarrollo humano (HDI compuesto, salud, educación e ingreso) para las 8 regiones administrativas de Guatemala. Dado que el GDL opera a nivel regional y no departamental, se construye un mapa explícito que asigna cada uno de los 22 departamentos a su región correspondiente.

Normalización de nombres de departamentos

```
norm_depto <- function(x) {
  x %>%
    str_trim() %>%
    str_squish() %>%
    stri_trans_general("Latin-ASCII") %>%
    str_to_lower()
}
```

Carga y limpieza de datos del INE

```
matrimonios_anual <- read_csv("matrimonios_depto_mes.csv", show_col_types = FALSE) %>%
  filter(nivel_geo == "departamento", is.na(mes)) %>%
  mutate(departamento = norm_depto(departamento)) %>%
  group_by(anio, departamento) %>%
  summarise(total_matrimonios = sum(valor, na.rm = TRUE), .groups = "drop")

divorcios_anual <- read_csv("divorcios_depto_mes.csv", show_col_types = FALSE) %>%
  filter(nivel_geo == "departamento", is.na(mes)) %>%
  mutate(departamento = norm_depto(departamento)) %>%
  group_by(anio, departamento) %>%
  summarise(total_divorcios = sum(valor, na.rm = TRUE), .groups = "drop")

dataset_ine <- matrimonios_anual %>%
  inner_join(divorcios_anual, by = c("anio", "departamento")) %>%
  mutate(tasa_divorcio_por_100 = (total_divorcios / total_matrimonios) * 100)
```

Carga de datos del GDL

```
archivos_gdl <- list.files(pattern = "GDL-Human-Development.*\\.csv$")

gdl_consolidado <- map_dfr(archivos_gdl, read_csv, show_col_types = FALSE) %>%
  filter(Level == "Subnat") %>%
  select(region_gdl = Region, anio = Year, shdi, healthindex, edindex, incindex)
```

Mapeo de departamentos a regiones GDL

```
region_map <- tibble(
  departamento = c(
    "guatemala",
    "alta verapaz", "baja verapaz",
    "el progreso", "izabal", "zacapa", "chiquimula",
    "santa rosa", "jalapa", "jutiapa",
    "chimaltenango", "sacatepequez", "escuintla",
    "san marcos", "quetzaltenango", "retalhuleu",
    "suchitepequez", "solola", "totonicapan",
    "huehuetenango", "quiche",
    "peten"
```

```

),
region_gdl = c(
  "Metropolitan",
  "North", "North",
  "North-Oriental", "North-Oriental", "North-Oriental",
  "South-Oriental", "South-Oriental", "South-Oriental",
  "Central", "Central", "Central",
  "South-Occidental", "South-Occidental", "South-Occidental",
  "South-Occidental", "South-Occidental", "South-Occidental",
  "North-Occidental", "North-Occidental",
  "Peten"
)
)

```

Join final y dataset completo

Los cuatro índices que provienen del GDL se interpretan como valores entre 0 y 1, donde valores más cercanos a 1 indican mejores condiciones:

- **SHDI** (*Subnational Human Development Index*): índice compuesto que resume el nivel de desarrollo humano de la región. Combina las tres dimensiones siguientes en un solo valor.
- **Health Index**: mide el nivel de salud de la población a partir de la esperanza de vida al nacer. Regiones con mayor acceso a servicios de salud y mejor calidad de vida tienden a valores más altos.
- **Educational Index** (*edindex*): refleja el acceso y los logros educativos de la población, considerando los años de escolaridad promedio y los años de escolaridad esperados.
- **Income Index** (*incindex*): aproxima el nivel de ingreso o poder adquisitivo de la región, basado en el ingreso nacional bruto per cápita ajustado.

Estos índices se asignan a nivel de región administrativa (8 regiones de Guatemala), por lo que todos los departamentos dentro de una misma región comparten el mismo valor para un año dado. Esto es una limitación conocida del dataset, que se menciona como parte de las restricciones del análisis.

```

dataset_final <- dataset_ine %>%
  left_join(region_map, by = "departamento") %>%
  left_join(gdl_consolidado, by = c("region_gdl", "anio")) %>%
  select(departamento, anio, total_matrimonios, total_divorcios,
         shdi, healthindex, edindex, incindex,
         tasa_divorcio_por_100)

glimpse(dataset_final)

```

```

## Rows: 308
## Columns: 9
## $ departamento      <chr> "alta verapaz", "baja verapaz", "chimaltenango", ~
## $ anio               <dbl> 2009, 2009, 2009, 2009, 2009, 2009, 2009, 2009, ~
## $ total_matrimonios  <dbl> 4300, 1334, 3099, 1766, 786, 2859, 11824, 5276, ~
## $ total_divorcios    <dbl> 129, 66, 56, 91, 47, 160, 1024, 84, 86, 79, 140, ~
## $ shdi               <dbl> 0.614, 0.614, 0.674, 0.657, 0.657, 0.674, 0.789, ~
## $ healthindex        <dbl> 0.768, 0.768, 0.758, 0.753, 0.753, 0.758, 0.790, ~
## $ edindex            <dbl> 0.517, 0.517, 0.591, 0.562, 0.562, 0.591, 0.783, ~
## $ incindex           <dbl> 0.584, 0.584, 0.683, 0.669, 0.669, 0.683, 0.794, ~
## $ tasa_divorcio_por_100 <dbl> 3.000000, 4.947526, 1.807035, 5.152888, 5.979644~

```

```
cat("Observaciones totales:", nrow(dataset_final), "\n")

## Observaciones totales: 308

cat("Departamentos únicos:", n_distinct(dataset_final$departamento), "\n")

## Departamentos únicos: 22

cat("Años cubiertos:", min(dataset_final$año), "-", max(dataset_final$año), "\n")

## Años cubiertos: 2009 - 2022
```

Conjuntos de Entrenamiento y Prueba

Método de partición

El dataset tiene una dimensión temporal explícita: cada observación corresponde a un departamento en un año específico. Una partición temporal estricta, entrenando en años anteriores y evaluando en los más recientes, concentraría el conjunto de prueba en los años 2019-2022, que fueron atípicos por los efectos de la pandemia. Evaluarse exclusivamente sobre años atípicos no ofrece una imagen representativa del desempeño real del modelo.

Por eso se optó por una **partición estratificada por año**: de cada uno de los 14 años se toma aleatoriamente el 70% de los departamentos para entrenamiento y el 30% restante para prueba. Esto garantiza que todos los años, incluidos los de pandemia, estén representados en ambos conjuntos, y permite comparar el comportamiento entre departamentos a lo largo de todo el período analizado.

```
set.seed(123)
porciento <- 0.7

años <- unique(dataset_final$año)

train_list <- list()
test_list <- list()

for (a in años) {
  año_data <- dataset_final[dataset_final$año == a, ]
  idx_train <- sample(nrow(año_data), porciento * nrow(año_data))
  train_list[[as.character(a)]] <- año_data[idx_train, ]
  test_list[[as.character(a)]] <- año_data[-idx_train, ]
}

train_set <- do.call(rbind, train_list)
test_set <- do.call(rbind, test_list)

cat("Entrenamiento:", nrow(train_set), "observaciones",
    sprintf("(%.1f%%)\n", 100 * nrow(train_set) / nrow(dataset_final)))

## Entrenamiento: 210 observaciones (68.2%)
```

```
cat("Prueba:          ", nrow(test_set), "observaciones",
    sprintf("(%.1f%%)\n", 100 * nrow(test_set) / nrow(dataset_final)))
```

```
## Prueba:          98 observaciones (31.8%)
```

Cada año aporta aproximadamente 15 departamentos al conjunto de entrenamiento y 7 al de prueba, resultando en una división cercana al 70/30 sobre las 308 observaciones totales.

Análisis de valores atípicos en la variable respuesta

Como la variable respuesta es cuantitativa continua, no aplica un análisis de balance. En su lugar se analizan los valores atípicos usando el criterio del rango intercuartílico (IQR): se considera atípico cualquier valor por debajo de $Q1 - 1.5 * IQR$ o por encima de $Q3 + 1.5 * IQR$.

```
Q1 <- quantile(dataset_final$tasa_divorcio_por_100, 0.25, na.rm = TRUE)
Q3 <- quantile(dataset_final$tasa_divorcio_por_100, 0.75, na.rm = TRUE)
IQR_val <- IQR(dataset_final$tasa_divorcio_por_100, na.rm = TRUE)

lim_inf <- Q1 - 1.5 * IQR_val
lim_sup <- Q3 + 1.5 * IQR_val

cat(sprintf("Q1: %.3f | Q3: %.3f | IQR: %.3f\n", Q1, Q3, IQR_val))
```


```
## Q1: 3.975 | Q3: 9.658 | IQR: 5.683
```

```
cat(sprintf("Límite inferior: %.3f | Límite superior: %.3f\n", lim_inf, lim_sup))
```

```
## Límite inferior: -4.549 | Límite superior: 18.182
```

```
ggplot(dataset_final, aes(y = tasa_divorcio_por_100)) +
  geom_boxplot(outlier.colour = "red", outlier.size = 2) +
  labs(
    title = "Distribución de la tasa de divorcio por cada 100 matrimonios",
    y      = "Divorcios por cada 100 matrimonios"
  ) +
  theme_minimal()
```

Distribución de la tasa de divorcio por cada 100 matrimonios



```
atipicos <- dataset_final %>%
  filter(tasa_divorcio_por_100 > lim_sup | tasa_divorcio_por_100 < lim_inf) %>%
  arrange(desc(tasa_divorcio_por_100))

cat("Total de observaciones atípicas:", nrow(atipicos), "\n\n")
```

```
## Total de observaciones atípicas: 8
```

```
atipicos %>% select(departamento, año, tasa_divorcio_por_100, total_matrimonios, total_divorcios)
```

```
## # A tibble: 8 x 5
##   departamento    año tasa_divorcio_por_100 total_matrimonios total_divorcios
##   <chr>          <dbl>         <dbl>          <dbl>          <dbl>
## 1 guatemala      2019          25.5          14477          3687
## 2 guatemala      2021          22.6          15382          3481
## 3 el progreso    2021          22.6           1027           232
## 4 guatemala      2022          22.4          15623          3494
## 5 el progreso    2022          18.7           979            183
## 6 quetzaltenango 2022          18.7           5131            957
## 7 jalapa         2022          18.6           1444            268
## 8 retalhuleu     2022          18.2           1927            351
```

Los atípicos detectados son observaciones reales del dataset, no errores de captura. El departamento de Guatemala concentra sistemáticamente las tasas más altas, lo que es consistente con los resultados del

Proyecto 1: ya en el clustering aparecía como un caso separado del resto del país. Esta diferencia responde a factores estructurales, mayor acceso a servicios legales, urbanización, densidad poblacional, y no a ruido en los datos.

Por eso no se eliminan. Los tres modelos los recibirán tal como están durante el entrenamiento. Si un modelo logra aprender que Guatemala se comporta distinto al resto, eso es precisamente lo que queremos que capture.

Variables finales para los modelos

Antes de pasar los datos a los modelos, se eliminan dos grupos de variables por razones distintas.

total_matrimonios y **total_divorcios** se excluyen porque introducirían fuga de información hacia la variable respuesta. La tasa se calcula directamente como $(\text{total_divorcios} / \text{total_matrimonios}) * 100$, por lo que ambas columnas contienen, implícitamente, el valor que el modelo intenta predecir. Incluirlas equivaldría a darle la respuesta antes de que haga la pregunta.

shdi se excluye porque es un índice compuesto que el GDL construye a partir de los tres índices que ya están en el dataset: **healthindex**, **edindex** e **incindex**. Mantenerlo junto a sus componentes generaría multicolinealidad y no aportaría información nueva.

Las variables que efectivamente se le pasan a los modelos son:

Variable	Rol	Tipo
departamento	Predictora	Categórica
anio	Predictora	Numérica
healthindex	Predictora	Numérica
edindex	Predictora	Numérica
incindex	Predictora	Numérica
tasa_divorcio_por_100	Respuesta	Numérica

```
vars_modelo <- c("departamento", "anio", "healthindex", "edindex", "incindex",
                 "tasa_divorcio_por_100")

train_modelo <- train_set %>% select(all_of(vars_modelo))
test_modelo <- test_set %>% select(all_of(vars_modelo))

glimpse(train_modelo)
```

```
## Rows: 210
## Columns: 6
## $ departamento    <chr> "retalhuleu", "solola", "quiche", "chimaltenango~
## $ anio            <dbl> 2009, 2009, 2009, 2009, 2009, 2009, 2009, 2009, ~
## $ healthindex     <dbl> 0.757, 0.757, 0.741, 0.758, 0.772, 0.772, 0.753,~
## $ edindex         <dbl> 0.561, 0.561, 0.467, 0.591, 0.560, 0.560, 0.562,~
## $ incindex        <dbl> 0.676, 0.676, 0.628, 0.683, 0.665, 0.665, 0.669,~
## $ tasa_divorcio_por_100 <dbl> 6.472303, 1.627781, 2.293458, 1.807035, 6.128782~
```

Preprocesamiento y Transformaciones

Escalado y normalización

Algunos algoritmos de aprendizaje automático son sensibles a la escala de las variables. En modelos como KNN o SVM, la distancia entre observaciones depende directamente de la magnitud de cada variable: si `año` va de 2009 a 2022 y `incindex` va de 0 a 1, el modelo le asignaría un peso desproporcionado al año simplemente porque sus valores son numéricamente más grandes. En esos casos, escalar o normalizar las variables antes de entrenar es indispensable.

Sin embargo, los tres modelos seleccionados en este proyecto no tienen esa dependencia:

- **Regresión Lineal Múltiple:** el escalado modifica la magnitud de los coeficientes estimados, pero no cambia las predicciones ni el ajuste del modelo. La relación entre predictores y variable respuesta se captura igual con o sin escala.
- **Árbol de Decisión:** los árboles trabajan haciendo cortes sobre umbrales de cada variable de forma independiente. Un corte en `incindex > 0.7` funciona exactamente igual que uno en `incindex_escalado > 1.2`; el resultado del árbol no cambia.
- **Random Forest:** al ser un ensamble de árboles de decisión, hereda la misma invarianza. La escala de las variables no afecta ni la estructura de los árboles ni la importancia relativa de las variables.

Por esta razón, los datos se pasan a los tres modelos sin ninguna transformación de escala.

Conversión de variable categórica

El único preprocesamiento aplicado es la representación de `departamento` como variable categórica. Al ser una variable con 22 valores posibles, uno por cada departamento de Guatemala, no puede ingresarse directamente como texto a un modelo numérico. Lo que se hace es convertirla en un conjunto de variables binarias: por cada departamento se crea una columna que toma el valor 1 si la observación corresponde a ese departamento y 0 en caso contrario. Esto se conoce como codificación dummy u one-hot encoding.

En la práctica, R maneja esto de forma automática cuando la variable está declarada como `factor`. Para regresión lineal, crea $n-1$ columnas binarias y deja un departamento como categoría de referencia para evitar multicolinealidad perfecta. Los modelos de árbol y Random Forest manejan el factor directamente sin necesidad de expandirlo en columnas, pero igualmente requieren que esté declarado como `factor` y no como texto plano.

Este es el único paso de preprocesamiento que se aplica antes de entrenar los tres modelos.

Métricas de Evaluación

Los tres algoritmos se compararán usando dos métricas calculadas sobre el conjunto de prueba (años 2019–2022). Calcularlas también sobre el conjunto de entrenamiento permitirá detectar sobreajuste.

R^2 - Coeficiente de Determinación

El R^2 indica qué proporción de la varianza de la variable respuesta es explicada por el modelo. Un R^2 de 0.80 significa que el modelo captura el 80% de la variabilidad en la tasa de divorcio; el 20% restante queda sin explicar. Es la métrica principal de ajuste porque habla en términos sustantivos: cuánto de lo que ocurre con el divorcio departamental puede atribuirse a las variables que tenemos.

Un R^2 alto en entrenamiento y notablemente más bajo en prueba es la señal más directa de sobreajuste: el modelo memorizó el conjunto de entrenamiento en lugar de aprender un patrón generalizable. Para este proyecto se considera aceptable una caída de hasta 10 puntos porcentuales entre entrenamiento y prueba.

RMSE - Raíz del Error Cuadrático Medio

El RMSE mide el error típico de predicción en las mismas unidades que la variable respuesta, es decir, en divorcios por cada 100 matrimonios. Un RMSE de 2.5 significa que en promedio el modelo se equivoca en 2.5 divorcios por cada 100 matrimonios. Al elevar los errores al cuadrado antes de promediar, penaliza más los errores grandes, lo que lo hace sensible a los valores atípicos. En este dataset eso es una propiedad deseable: el departamento de Guatemala concentra las tasas más altas y los errores sobre él deben pesar en la evaluación.

Se prefiere RMSE sobre MAE porque los errores grandes son cualitativamente más graves en este contexto: subestimar significativamente la tasa de un departamento tiene mayores implicaciones de política pública que subestimarla levemente. Se prefiere sobre el MSE porque al tomar la raíz cuadrada el resultado es directamente interpretable en las mismas unidades que la variable respuesta, a diferencia del MSE que quedaría expresado en divorcios al cuadrado por cada 100 matrimonios al cuadrado.

Criterio de Selección

El mejor modelo de cada algoritmo será el de menor RMSE en el conjunto de prueba, siempre que no presente sobreajuste (caída de R^2 mayor a 10 puntos porcentuales entre entrenamiento y prueba). Si dos modelos tienen RMSE comparable, se prefiere el de mayor R^2 o el más simple.

```
rmse_fn <- function(actual, predicted) sqrt(mean((actual - predicted)^2))
r2_fn   <- function(actual, predicted) {
  1 - sum((actual - predicted)^2) / sum((actual - mean(actual))^2)
}
```

Regresión Lineal Múltiple

Variante 1

Hiperparámetros y Justificación

COMPLETAR

Indicar qué especificación del modelo se usa en esta variante (qué predictores incluye) y justificar por qué.

Entrenamiento y Resultados

COMPLETAR

Código de entrenamiento. Reportar RMSE y R^2 en entrenamiento y en prueba.

Variante 2

Hiperparámetros y Justificación

COMPLETAR

Indicar qué cambia respecto a la Variante 1 y justificar el cambio.

Entrenamiento y Resultados

COMPLETAR

Código de entrenamiento. Reportar RMSE y R^2 en entrenamiento y en prueba.

Variante 3

Hiperparámetros y Justificación

COMPLETAR

Indicar qué cambia respecto a las variantes anteriores y justificar el cambio.

Entrenamiento y Resultados

COMPLETAR

Código de entrenamiento. Reportar RMSE y R^2 en entrenamiento y en prueba.

Selección del Mejor Modelo de Regresión Lineal

COMPLETAR

Tabla comparativa de las tres variantes (RMSE y R^2 en entrenamiento y prueba). Justificar cuál variante se selecciona como la mejor y por qué.

Árbol de Decisión

El árbol de decisión predice la tasa de divorcio por cada 100 matrimonios a partir de cinco predictores: el departamento (captura dónde vive la población), el año (tendencia temporal), y los tres índices del GDL (healthindex, edindex, incindex), que aproximan condiciones socioeconómicas estrechamente relacionadas con los patrones demográficos, incluidos los rangos de edad al matrimonio y al divorcio documentados en el Proyecto 1. A diferencia de la regresión lineal, el árbol identifica umbrales naturales en estas variables, lo que le permite capturar relaciones no lineales sin necesidad de especificarlas de antemano.

```

abrev_depto <- c(
  "alta verapaz" = "AV", "baja verapaz" = "BV",
  "chimaltenango" = "CML", "chiquimula" = "CQM",
  "el progreso" = "EP", "escuintla" = "ESC",
  "guatemala" = "GT", "huehuetenango" = "HUE",
  "izabal" = "IZA", "jalapa" = "JAL",
  "jutiapa" = "JUT", "peten" = "PET",
  "quetzaltenango" = "QUE", "quiche" = "QUI",
  "retalhuleu" = "RET", "sacatepequez" = "SAC",
  "san marcos" = "SM", "santa rosa" = "SR",
  "solola" = "SOL", "suchitepequez" = "SUC",
  "totonicapan" = "TOT", "zacapa" = "ZAC"
)

niveles_depto <- sort(unique(dataset_final$departamento))
train_modelo$departamento <- factor(train_modelo$departamento, levels = niveles_depto)
test_modelo$departamento <- factor(test_modelo$departamento, levels = niveles_depto)

levels(train_modelo$departamento) <- abrev_depto[levels(train_modelo$departamento)]
levels(test_modelo$departamento) <- abrev_depto[levels(test_modelo$departamento)]

cat("Abreviaturas utilizadas:\n")

```

Abreviaturas utilizadas:

```
print(abrev_depto)
```

```

##  alta verapaz  baja verapaz  chimaltenango  chiquimula  el progreso
##      "AV"      "BV"      "CML"      "CQM"      "EP"
##  escuintla    guatemala  huehuetenango    izabal    jalapa
##      "ESC"      "GT"      "HUE"      "IZA"      "JAL"
##      jutiapa      peten  quetzaltenango    quiche    retalhuleu
##      "JUT"      "PET"      "QUE"      "QUI"      "RET"
##  sacatepequez  san marcos  santa rosa    solola  suchitepequez
##      "SAC"      "SM"      "SR"      "SOL"      "SUC"
##  totonicapan    zacapa
##      "TOT"      "ZAC"

```

Variante 1

Hiperparámetros y Justificación La primera variante usa los parámetros más conservadores del árbol para establecer una línea base controlada:

- **cp = 0.05**: parámetro de complejidad (*complexity parameter*). Un nodo solo se divide si esa partición reduce el error relativo en al menos 5%. Es el valor por defecto de **rpart** y produce una poda implícita razonable.
- **maxdepth = 3**: limita el árbol a tres niveles desde la raíz. Con 308 observaciones y 22 posibles valores de departamento, mayor profundidad incrementa el riesgo de memorizar el conjunto de entrenamiento.
- **minsplit = 10**: exige al menos 10 observaciones en un nodo antes de intentar dividirlo, evitando ramas creadas a partir de muy pocos datos.

Esta variante sirve como referencia: un árbol sin restricciones extremas pero tampoco sin control.


```

set.seed(123)
tree_v1 <- rpart(
  tasa_divorcio_por_100 ~ departamento + anio + healthindex + edindex + incindex,
  data = train_modelo,
  method = "anova",
  control = rpart.control(cp = 0.05, maxdepth = 3, minsplit = 10)
)

rpart.plot(tree_v1, type = 4, extra = 101, fallen.leaves = TRUE,
  main = "Árbol de Decisión - Variante 1 (cp=0.05, maxdepth=3)")

```

Árbol de Decisión - Variante 1 (cp=0.05, maxdepth=3)



```

pred_train_v1 <- predict(tree_v1, train_modelo)
pred_test_v1 <- predict(tree_v1, test_modelo)

rmse_train_v1 <- rmse_fn(train_modelo$tasa_divorcio_por_100, pred_train_v1)
rmse_test_v1 <- rmse_fn(test_modelo$tasa_divorcio_por_100, pred_test_v1)
r2_train_v1 <- r2_fn(train_modelo$tasa_divorcio_por_100, pred_train_v1)
r2_test_v1 <- r2_fn(test_modelo$tasa_divorcio_por_100, pred_test_v1)

cat(sprintf("Entrenamiento - RMSE: %.4f | R²: %.4f\n", rmse_train_v1, r2_train_v1))

```

Entrenamiento y Resultados

```
## Entrenamiento - RMSE: 2.0744 | R²: 0.7931
```

```
cat(sprintf("Prueba          - RMSE: %.4f | R²: %.4f\n", rmse_test_v1, r2_test_v1))
```

```
## Prueba          - RMSE: 2.5815 | R²: 0.5171
```

Variante 2


Hiperparámetros y Justificación La segunda variante relaja las restricciones para explorar si mayor capacidad expresiva mejora el desempeño en prueba o si el árbol simplemente memoriza el entrenamiento:

- **cp = 0.01**: umbral cinco veces menor que en la Variante 1. Permite divisiones que aporten mejoras más pequeñas en el error, generando árboles más profundos y ramificados.
- **maxdepth = 5**: duplica el límite de profundidad, permitiendo capturar interacciones más complejas entre departamento y los índices del GDL.
- **minsplit = 5**: permite dividir nodos con solo 5 observaciones, añadiendo flexibilidad adicional pero incrementando el riesgo de sobreajuste.

```
set.seed(123)
tree_v2 <- rpart(
  tasa_divorcio_por_100 ~ departamento + anio + healthindex + edindex + incindex,
  data      = train_modelo,
  method    = "anova",
  control   = rpart.control(cp = 0.01, maxdepth = 5, minsplit = 5)
)

rpart.plot(tree_v2, type = 4, extra = 101, fallen.leaves = TRUE,
  main = "Árbol de Decisión - Variante 2 (cp=0.01, maxdepth=5)")
```

Árbol de Decisión – Variante 2 (cp=0.01, maxdepth=5)



```
pred_train_v2 <- predict(tree_v2, train_modelo)
pred_test_v2  <- predict(tree_v2, test_modelo)

rmse_train_v2 <- rmse_fn(train_modelo$tasa_divorcio_por_100, pred_train_v2)
rmse_test_v2  <- rmse_fn(test_modelo$tasa_divorcio_por_100, pred_test_v2)
r2_train_v2   <- r2_fn(train_modelo$tasa_divorcio_por_100, pred_train_v2)
r2_test_v2    <- r2_fn(test_modelo$tasa_divorcio_por_100, pred_test_v2)

cat(sprintf("Entrenamiento - RMSE: %.4f | R²: %.4f\n", rmse_train_v2, r2_train_v2))
```

Entrenamiento y Resultados

```
## Entrenamiento - RMSE: 1.5351 | R²: 0.8867
```

```
cat(sprintf("Prueba          - RMSE: %.4f | R²: %.4f\n", rmse_test_v2, r2_test_v2))
```

```
## Prueba          - RMSE: 2.2511 | R²: 0.6328
```

Variante 3

Hiperparámetros y Justificación La tercera variante aplica **poda formal** mediante **validación cruzada interna** de `rpart`, usando la regla del 1-SE (*one standard error rule*): entre todos los valores


de `cp` cuyo error de validación cruzada está dentro de un error estándar del mínimo, se selecciona el mayor, es decir, el árbol más simple con desempeño estadísticamente comparable al óptimo.

El procedimiento es:

1. Crecer un árbol muy profundo (`cp = 0.0001`, `maxdepth = 15`) para explorar el espacio completo de divisiones.
2. Leer la tabla de errores de validación cruzada (`cptable`).
3. Identificar el `cp` óptimo con la regla 1-SE.
4. Podar el árbol con `prune()` al `cp` óptimo.

Este es el enfoque recomendado en la literatura para controlar el sobreajuste, ya que delega la elección del nivel de poda en evidencia empírica y no en un valor fijo elegido a priori.

```
set.seed(123)
tree_full <- rpart(
  tasa_divorcio_por_100 ~ departamento + anio + healthindex + edindex + incindex,
  data      = train_modelo,
  method    = "anova",
  control   = rpart.control(cp = 0.0001, maxdepth = 15, minsplit = 5)
)
plotcp(tree_full)
```



```

cp_tabla <- tree_full$cptable
min_xerr <- min(cp_tabla[, "xerror"])
se_min <- cp_tabla[which.min(cp_tabla[, "xerror"]), "xstd"]
cp_opt <- cp_tabla[cp_tabla[, "xerror"] <= min_xerr + se_min, "CP"][1]
cat(sprintf("cp óptimo seleccionado (regla 1-SE): %.6f\n", cp_opt))


## cp óptimo seleccionado (regla 1-SE): 0.003221

tree_v3 <- prune(tree_full, cp = cp_opt)

rpart.plot(tree_v3, type = 4, extra = 101, fallen.leaves = TRUE,
  main = "Árbol de Decisión - Variante 3 (cp óptimo, regla 1-SE)")

```

Árbol de Decisión - Variante 3 (cp óptimo, regla 1-SE)



```

pred_train_v3 <- predict(tree_v3, train_modelo)
pred_test_v3 <- predict(tree_v3, test_modelo)

rmse_train_v3 <- rmse_fn(train_modelo$tasa_divorcio_por_100, pred_train_v3)
rmse_test_v3 <- rmse_fn(test_modelo$tasa_divorcio_por_100, pred_test_v3)
r2_train_v3 <- r2_fn(train_modelo$tasa_divorcio_por_100, pred_train_v3)
r2_test_v3 <- r2_fn(test_modelo$tasa_divorcio_por_100, pred_test_v3)

cat(sprintf("Entrenamiento - RMSE: %.4f | R²: %.4f\n", rmse_train_v3, r2_train_v3))

```

Entrenamiento y Resultados

```
## Entrenamiento - RMSE: 1.1718 | R2: 0.9340
```

```
cat(sprintf("Prueba          - RMSE: %.4f | R2: %.4f\n", rmse_test_v3, r2_test_v3))
```

```
## Prueba          - RMSE: 1.9727 | R2: 0.7180
```

Selección del Mejor Modelo de Árbol de Decisión

```
comparacion_tree <- data.frame(  
  Variante = c("V1: cp=0.05, maxdepth=3",  
               "V2: cp=0.01, maxdepth=5",  
               "V3: cp óptimo (1-SE)"),  
  RMSE_Train = round(c(rmse_train_v1, rmse_train_v2, rmse_train_v3), 4),  
  R2_Train   = round(c(r2_train_v1,   r2_train_v2,   r2_train_v3),   4),  
  RMSE_Test  = round(c(rmse_test_v1,  rmse_test_v2,  rmse_test_v3), 4),  
  R2_Test    = round(c(r2_test_v1,    r2_test_v2,    r2_test_v3),    4)  
)  
  
knitr::kable(  
  comparacion_tree,  
  col.names = c("Variante", "RMSE Train", "R2 Train", "RMSE Test", "R2 Test"),  
  caption   = "Comparación de variantes - Árbol de Decisión"  
)
```

Table 2: Comparación de variantes — Árbol de Decisión

Variante	RMSE Train	R ² Train	RMSE Test	R ² Test
V1: cp=0.05, maxdepth=3	2.0744	0.7931	2.5815	0.5171
V2: cp=0.01, maxdepth=5	1.5351	0.8867	2.2511	0.6328
V3: cp óptimo (1-SE)	1.1718	0.9340	1.9727	0.7180

```
mejor_idx <- which.min(comparacion_tree$RMSE_Test)  
caida_r2  <- comparacion_tree$R2_Train[mejor_idx] - comparacion_tree$R2_Test[mejor_idx]  
  
cat(sprintf("\nMejor variante por RMSE Test: %s\n", comparacion_tree$Variante[mejor_idx]))
```

```
##  
## Mejor variante por RMSE Test: V3: cp óptimo (1-SE)
```

```
cat(sprintf("RMSE Test: %.4f | R2 Test: %.4f\n",  
            comparacion_tree$RMSE_Test[mejor_idx],  
            comparacion_tree$R2_Test[mejor_idx]))
```

```
## RMSE Test: 1.9727 | R2 Test: 0.7180
```

```
cat(sprintf("Caída de  $R^2$  (train  $\rightarrow$  test): %.4f puntos porcentuales\n", caida_r2 * 100))
```

```
## Caída de  $R^2$  (train  $\rightarrow$  test): 21.6000 puntos porcentuales
```

```
if (caida_r2 > 0.10) {  
  cat("Advertencia: caída de  $R^2$  mayor al 10% - posible sobreajuste.\n")  
} else {  
  cat("Sin sobreajuste significativo detectado.\n")  
}
```

```
## Advertencia: caída de  $R^2$  mayor al 10% - posible sobreajuste.
```

La Variante 3 es la opción metodológicamente más sólida porque la elección de `cp` surge de los propios datos de entrenamiento (validación cruzada interna) y no de un valor fijo. Si su RMSE en prueba es comparable al de las otras variantes, se selecciona como el mejor árbol por su menor riesgo de sobreajuste. En caso de que la Variante 1 o 2 presente un RMSE notablemente menor sin una caída de R^2 superior a 10 puntos, se priorizaría esa variante.

Random Forest

Variante 1

Hiperparámetros y Justificación

COMPLETAR

Indicar los valores de `ntree`, `mtry` y cualquier otro parámetro usado. Explicar qué controla cada hiperparámetro y por qué se eligieron esos valores.

Entrenamiento y Resultados

COMPLETAR

Código de entrenamiento. Reportar RMSE y R^2 en entrenamiento y en prueba.

Variante 2

Hiperparámetros y Justificación

COMPLETAR

Indicar qué cambia respecto a la Variante 1 y justificar el cambio.

Entrenamiento y Resultados

COMPLETAR

Código de entrenamiento. Reportar RMSE y R^2 en entrenamiento y en prueba.

Variante 3

Hiperparámetros y Justificación

COMPLETAR

Indicar qué cambia respecto a las variantes anteriores y justificar el cambio. Incluir gráfica de importancia de variables (`varImpPlot`) e interpretar cuál predictor pesa más.

Entrenamiento y Resultados

COMPLETAR

Código de entrenamiento. Reportar RMSE y R^2 en entrenamiento y en prueba.

Selección del Mejor Modelo de Random Forest

COMPLETAR

Tabla comparativa de las tres variantes (RMSE y R^2 en entrenamiento y prueba). Justificar cuál variante se selecciona como la mejor y por qué.

Comparación Final entre Algoritmos

COMPLETAR

Tabla con el mejor modelo de cada algoritmo (RMSE y R^2 en prueba). Gráfica de valores reales vs. predichos para el mejor modelo general. Discutir cuál algoritmo obtuvo el mejor desempeño, si la ganancia de complejidad se justifica, y si algún modelo presenta sobreajuste que lo descalifique.

Referencias

- Al-Otaibi, A., Alotaibi, B., & Alzahrani, I. (2024). Divorce prediction using machine learning algorithms in Ha'il region, KSA. *Scientific Reports*, 14, 481. <https://www.nature.com/articles/s41598-023-50839-1>
- Dogan, H., & Kılınç, E. (2025). Unpacking divorce: Feature-based machine learning interpretation of sociological patterns. *Social Science Computer Review*. <https://journals.sagepub.com/doi/10.1177/08944393251386073>
- Esteve, A., Lesthaeghe, R., López-Colás, J., & López-Gay, A. (2023). The changing social gradient of marriage and cohabitation in seven Latin American countries. *Social Science Research*, 114, 102898. <https://www.sciencedirect.com/science/article/pii/S0049089X23000534>
- Fareed, S., Ghani, U., Ali, S., & Hussain, W. (2022). Predicting divorce prospect using ensemble learning: Support vector machine, linear model, and neural network. *Computational Intelligence and Neuroscience*, 2022, 3687598. <https://pmc.ncbi.nlm.nih.gov/articles/PMC9293523/>
- Mbaye, E. H., Al-Kindi, M., & Al-Alawi, A. (2020). The effects of sociodemographic characteristics on divorce rates in Oman: Spatial modeling of marital separations. *Journal of Population Research*, 37(3), 225–247. <https://www.researchgate.net/publication/340111582>
- Papageorgiou, I., & Velásquez, R. (2025). When the economy breaks down, do marriages follow? Crisis type and family dissolution across 83 countries (1990–2019). *Applied Research in Quality of Life*. <https://link.springer.com/article/10.1007/s11482-025-10540-z>
- Yöntem, M. K., Adem, K., İlhan, T., & Kılçarslan, S. (2019). Divorce prediction using correlation based feature selection and artificial neural networks. *Neuşehir Hacı Bektaş Veli University Journal of ISS*, 9(1), 259–273. https://www.researchgate.net/publication/373398266_Divorce_Prediction_Using_Machine_Learning_Methodology